Lec-07

Lock & Latch

DB中的Lock的作用对象是table,tuple等DB中的entities实现事务的隔离

Latch更像是低级的同步原语如信号量,spinLock,用于保证对临界区访问的线程安全,实现的是线程的隔离,在OS中并没有Latch的概念，DB中的Latch更偏向于OS中的Lock

Latch Implementation Goals

- 不要去造Latch的轮子
- Latch是没有线程的等待队列的
- Don't use spinLock in userspace, you can never perform better than what the kernel can do.

Latch Implementations

- Test-and-Set SpinLock

1.硬件支持,单条指令提供上锁解锁的原子操作

```
TSL RX,LOCK
```

读取LOCK值->读取的值存入到寄存器RX->给LOCK设置非0的值

上面的三个步骤是不可拆分的原子操作，执行该指令的CPU会锁住内存总线，导致其他CPU不能访问内存。

顺便说说关中断和TSL的区别:

中断屏蔽只会影响当前的CPU，其他CPU依然能够访问内存，因此中断屏蔽只适用于单处理器

而想要别的处理器访问不到内存只能使用TSL

Java里面的自旋锁应该可以用Unsafe或者VarHandler的CAS实现

但一般不采用这种方法实现Latch,一是不能进入临界区的资源会不断自旋损耗CPU，二是可能会有cache invalidation就是缓存一致性的一些issue

- Blocking OS Mutex

类似于Linux内核中的Futex

右下角大概讲述了工作原理:

假设有两个CPU竞争，第一个会竞争到Userspace的Latch，如果失败了就会占有OS的Latch，然后一直等待等到另一个CPU释放Userspace的Latch。总所周知涉及到OS肯定会有syscall,这样性能也会很差好吧

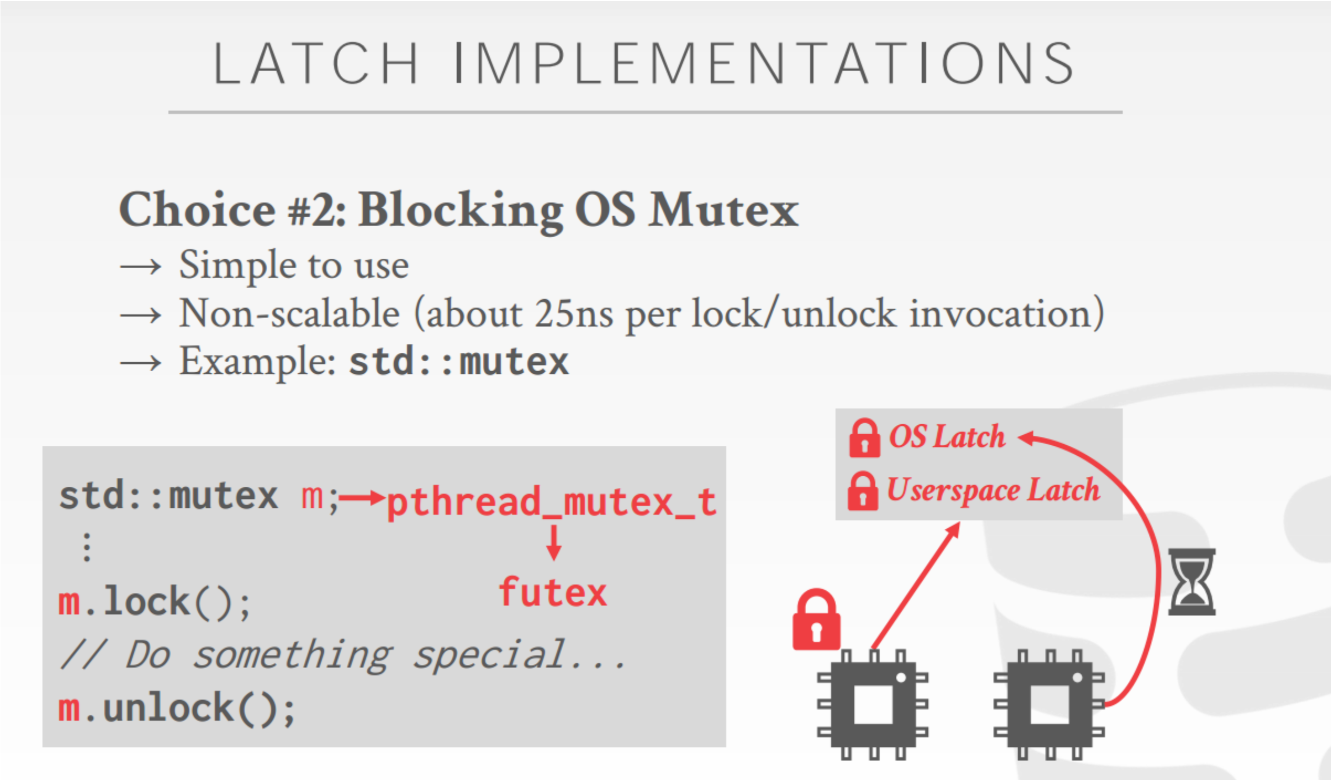

- Adaptive SpinLock (Right thing to choose)

如上面不同，如果线程竞争Userspace的latch失败了,他们会暂时阻塞并且存储到一个全局变量"parking lot"，就好像到停车场泊车一样。然后如果又有别的线程进来了，看到停车场"有车了"，即有别的线程已经在等待userspace的latch,那么它就不会去那么傻再自旋而是直接也进入parking lot，减少CPU损耗对吧。

- Queue-based SpinLock

MCS spinLock in Linux Kernel这里简单介绍下

你想，如果spinLock变量发生变化，所有尝试获取这个spinLock的CPU都需要从内存读取然后刷新到自己对应的缓存行，但最终只能有一个CPU可以获得锁，只有它的刷新是有意义的，锁的竞争越激烈，这种无效的开销就会越多。

大概意思是说假设CPU1的线程占有Base Latch,现在CPU2的线程进来了，发现Base Latch已经被别的线程占有了。咋办？如果CPU2也是在Base Latch自旋，那么就会有上一段我讲的问题。这里的做法是CPU2会在Base Latch的分身CPU1 Latch自旋，具体是维护一个Latch队列，依次把新的线程对应的Latch加入到这个队列中。

当CPU1释放Base Latch之后，接下来队首就是CPU1 Latch了对吧，这个时候CPU2就可以占有这个Base Latch了...以此类推。

说白了就是防止多个线程同时在一个memory space的latch做spinning，避免因此而产生的缓存不一致所造成的性能损耗。

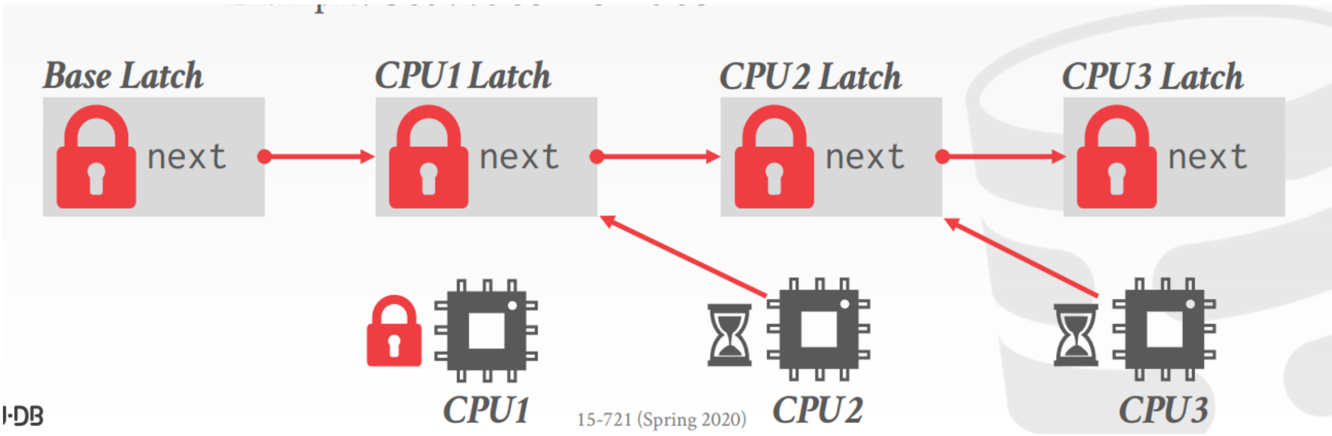

- Reader-Writer Lock

啊我记得阿里云面试就问过我自旋锁和读写锁性能的对比...分别在啥场景下适用，可惜当时答得不怎么样

1.允许并发读

2.需要对读写线程分别维护线程队列以避免饥饿

3.可以在spinLock基础上实现

下面给出例子:

读写锁分别维护现在占有锁的线程数量和等待锁的线程数量

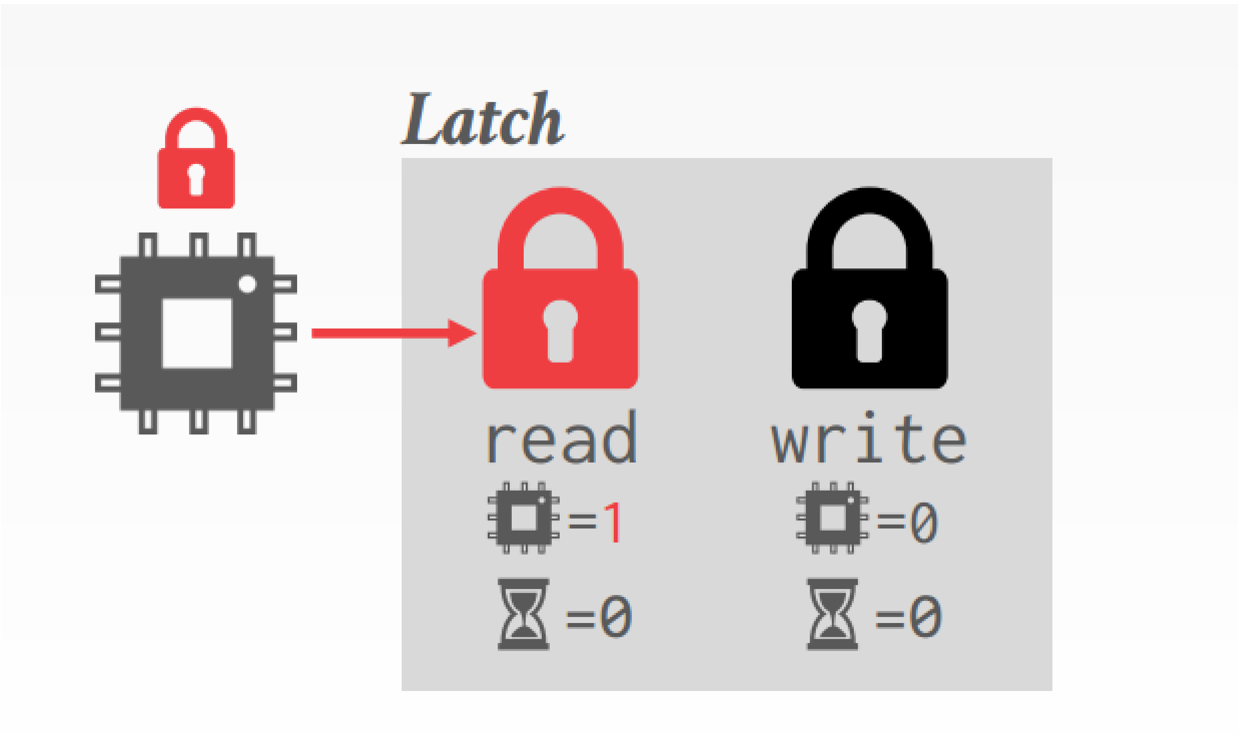

那么现在来了两个读线程，他们并不是互斥的，可以共享读锁

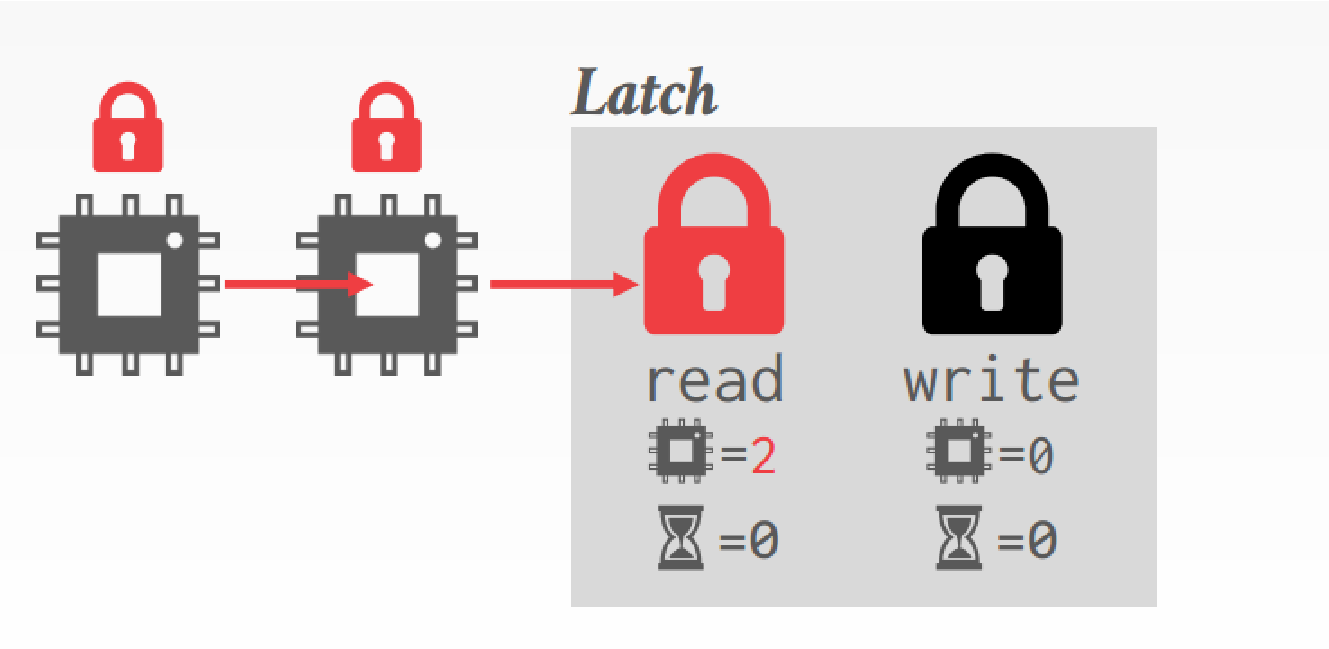

这时候呢来了个写线程，由于读锁现在有两个线程占有，写线程只能入队等待了

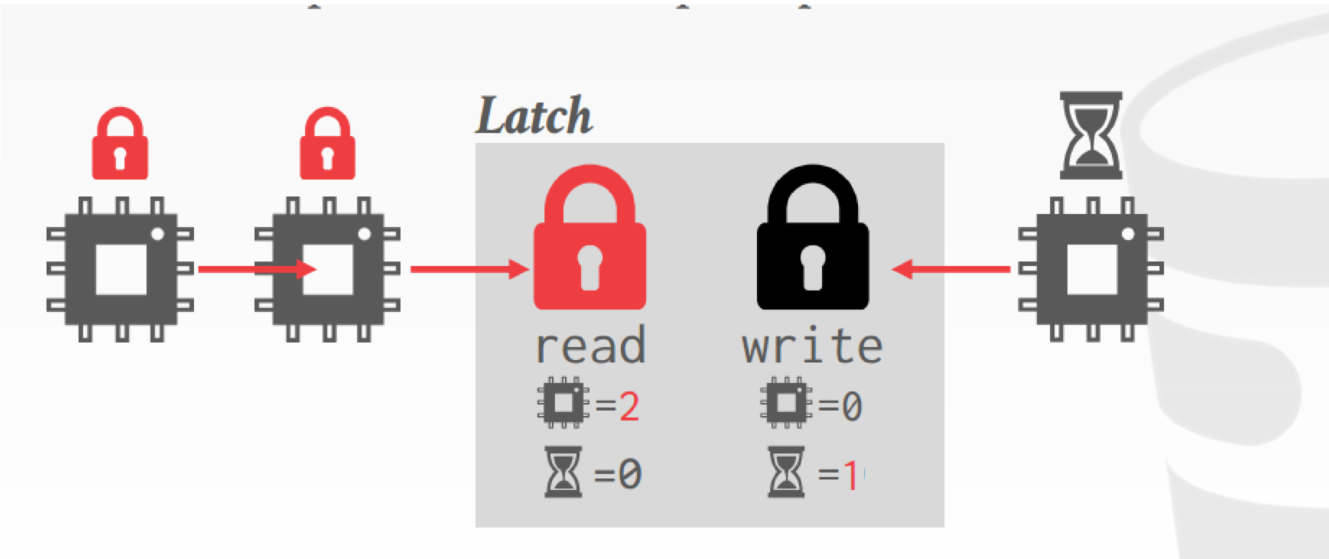

这时候呢有一条新的读线程进来了，因为这时候有写锁等待着，所以新的读线程只能入队等待

Latch Crabbing & Latch Coupling

- Acquire and release latches on B+ Tree nodes.

那啥时候可以释放掉结点的latch呢?

如果你的子节点可以被视为安全的，那么可以释放其父节点的latch。

那什么是安全啊？（战术后仰

具体来说如果一个节点不会split或者merge就可以说是安全的

就例如insert时候如果结点不是满的，就是安全的。满了的话就会split

或者如果删除操作的时候，节点数量已经超过一半了，那也是安全的。否则如果没有一半的话，就会merge到其他结点

对于**search**操作，从根节点开始往下遍历

1.对子节点获取读latch

2.然后释放父节点的latch

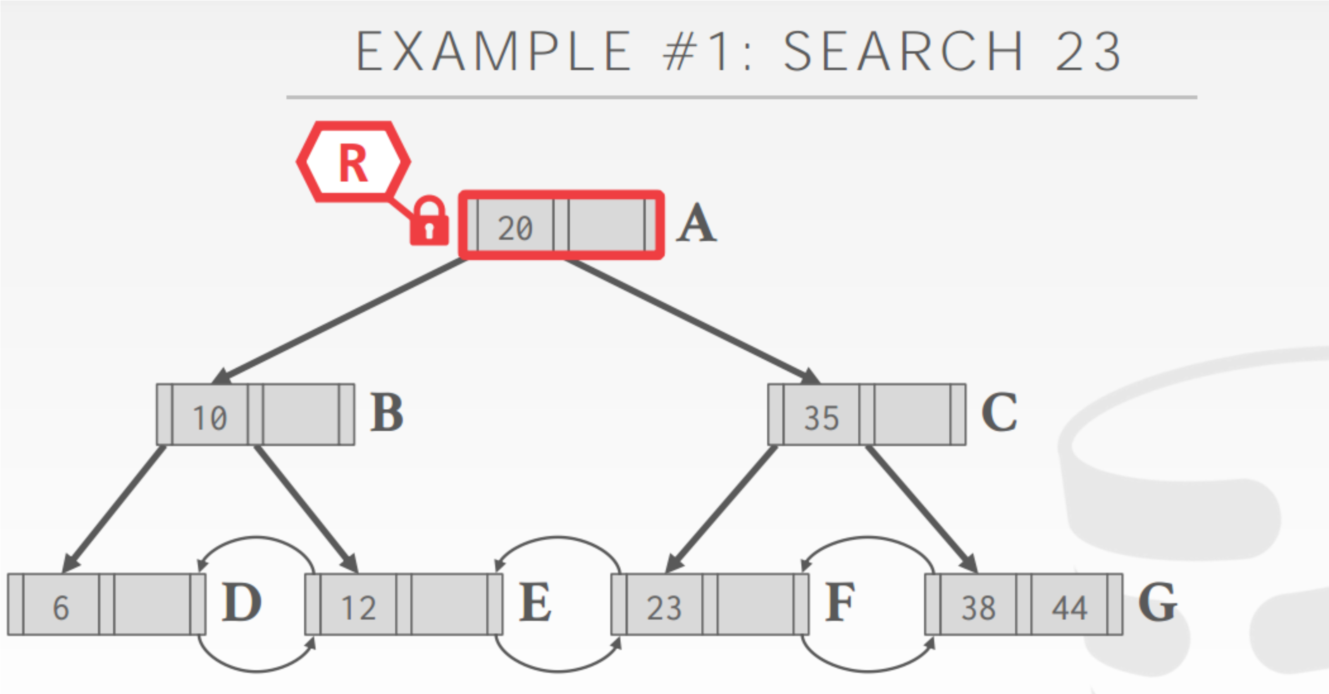

如下图，一旦获得了C的锁，就可以释放其父节点A的锁

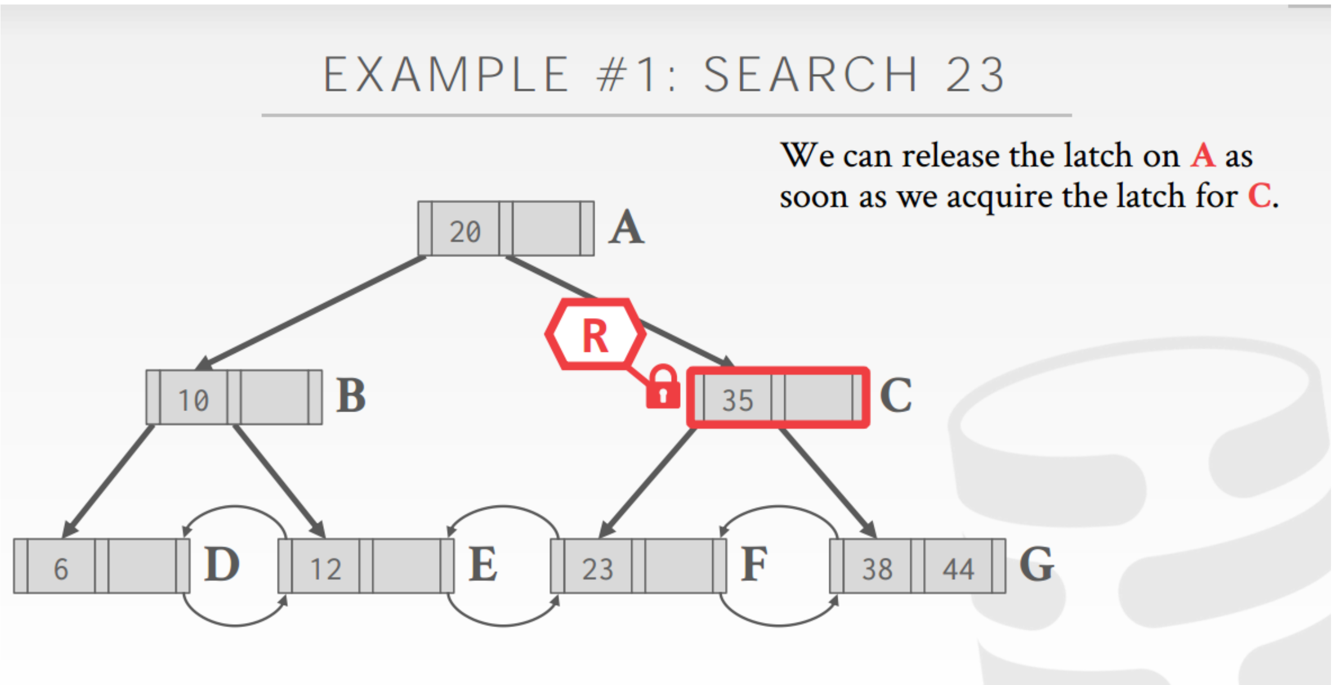

以此类推最后找到F

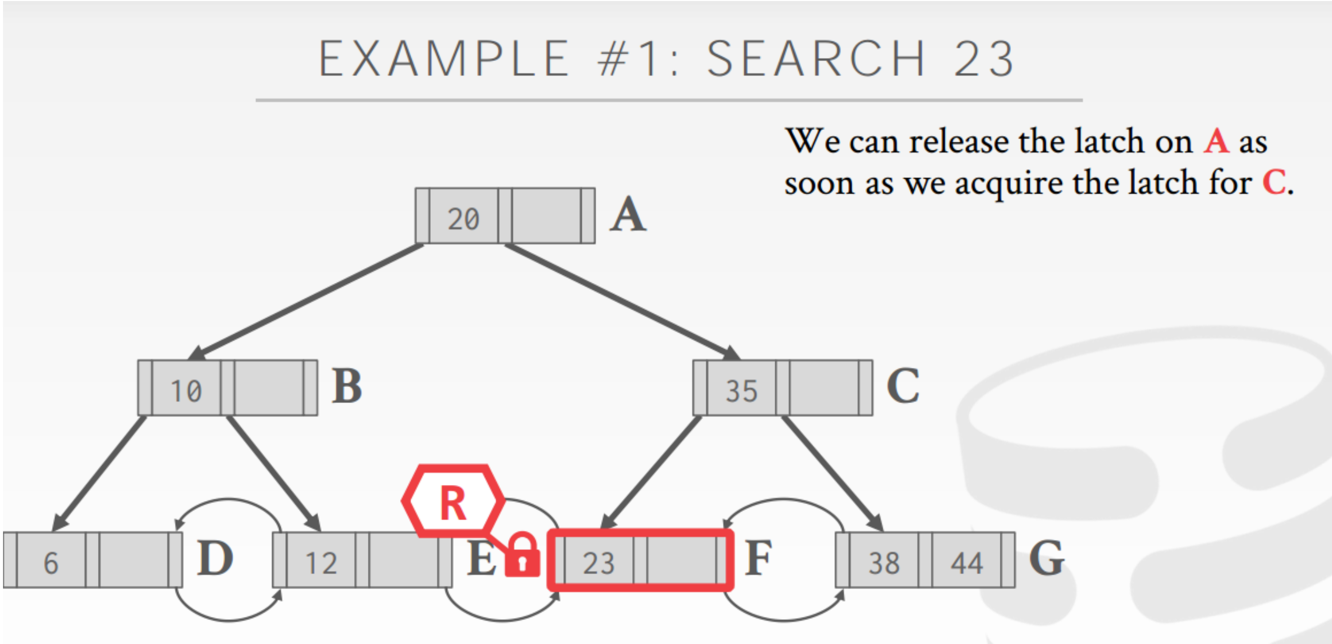

对于**insert，delete**操作，从根节点往下遍历，然后获取写latch，一旦子节点上锁了，就检查其是否安全。如果子节点安全，释放其所有父节点的latch。

delete操作：

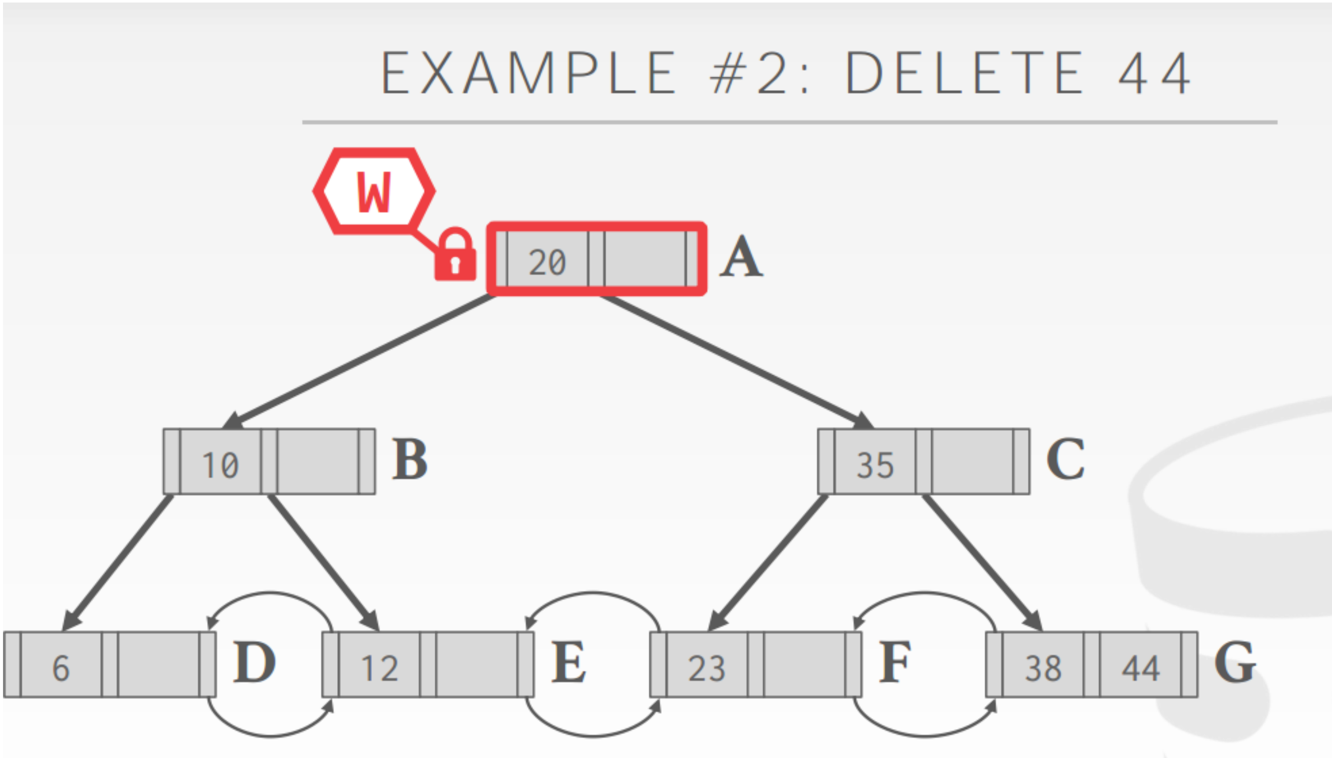

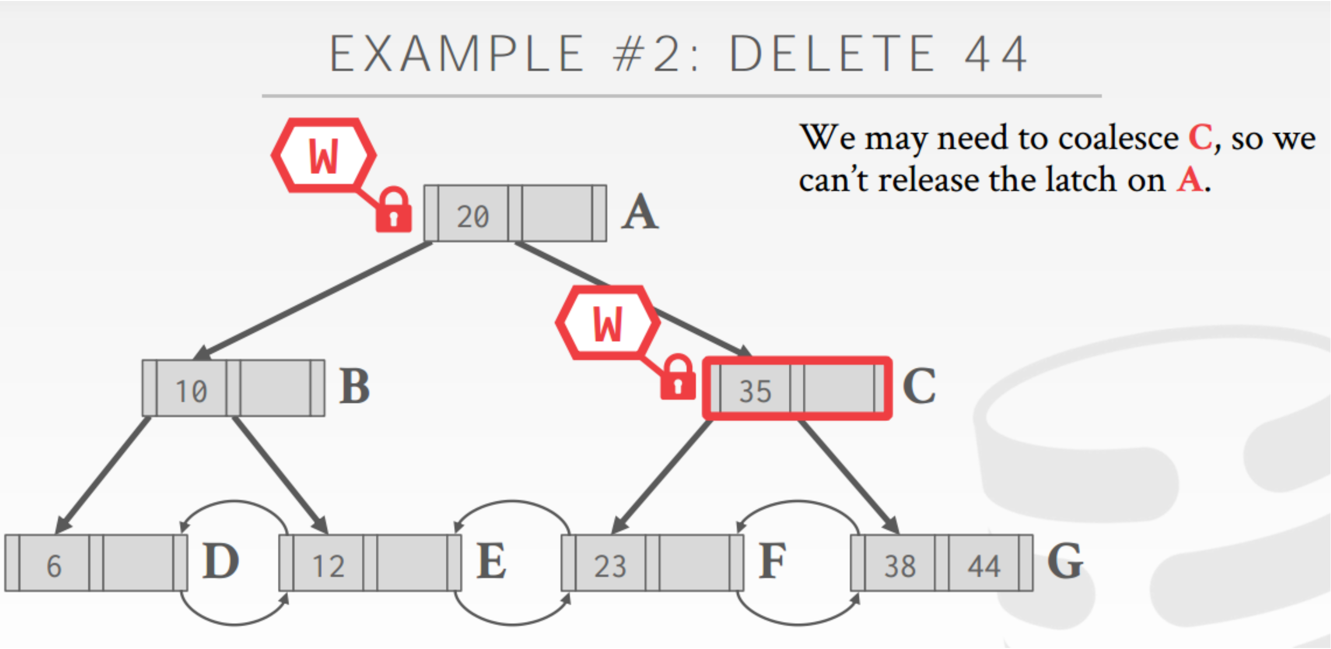

一直找到44之前A,C都不能解锁，因为不能判断C是否安全，C可能会合并到其他结点

然后判断G结点删除之后是否会与F结点merge，如果不会数目G是安全的，这时候才可以释放其所有父节点上的锁。

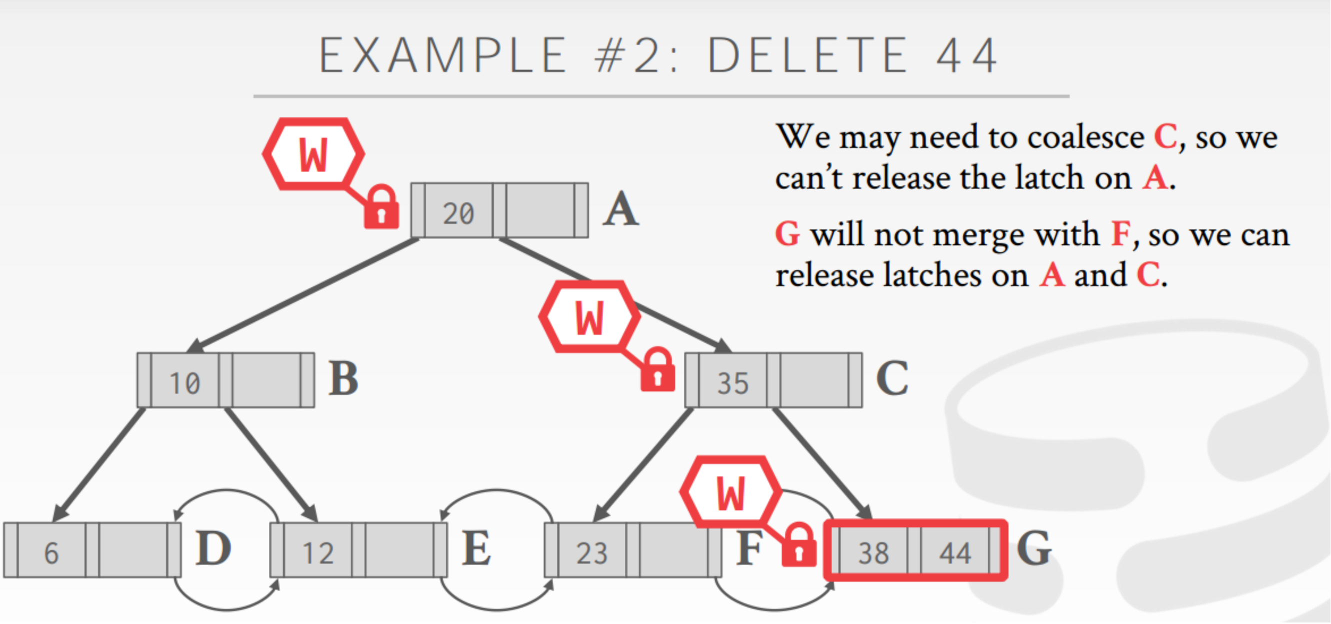

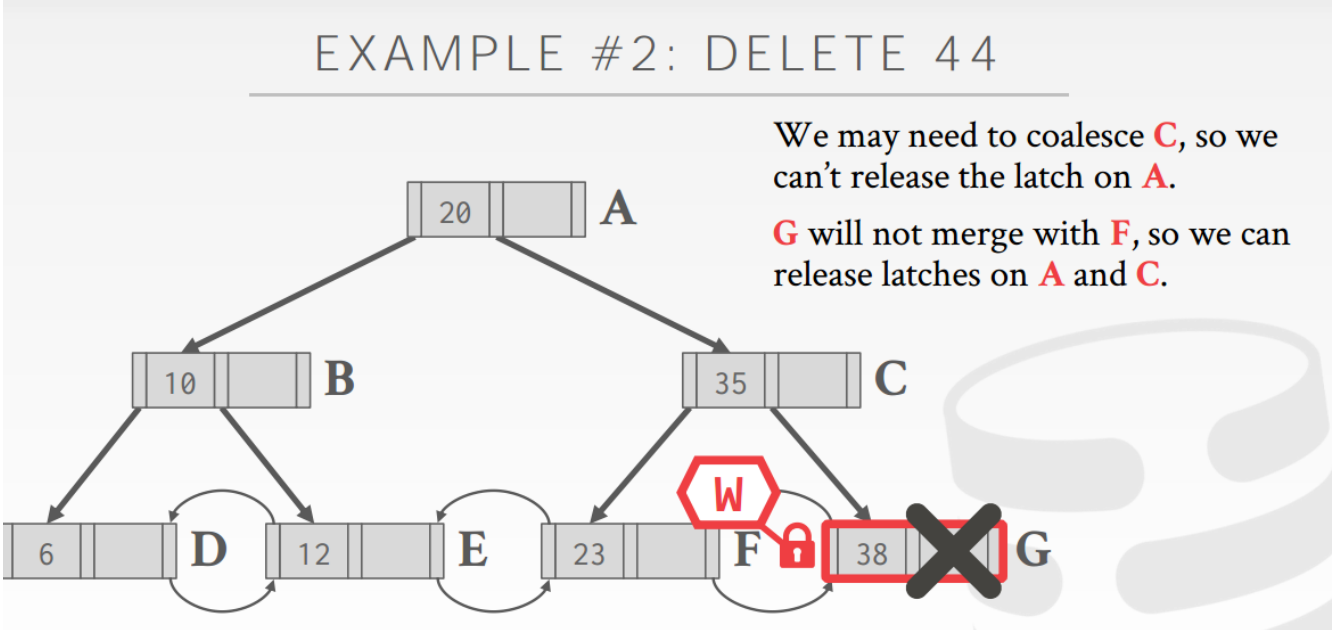

insert操作

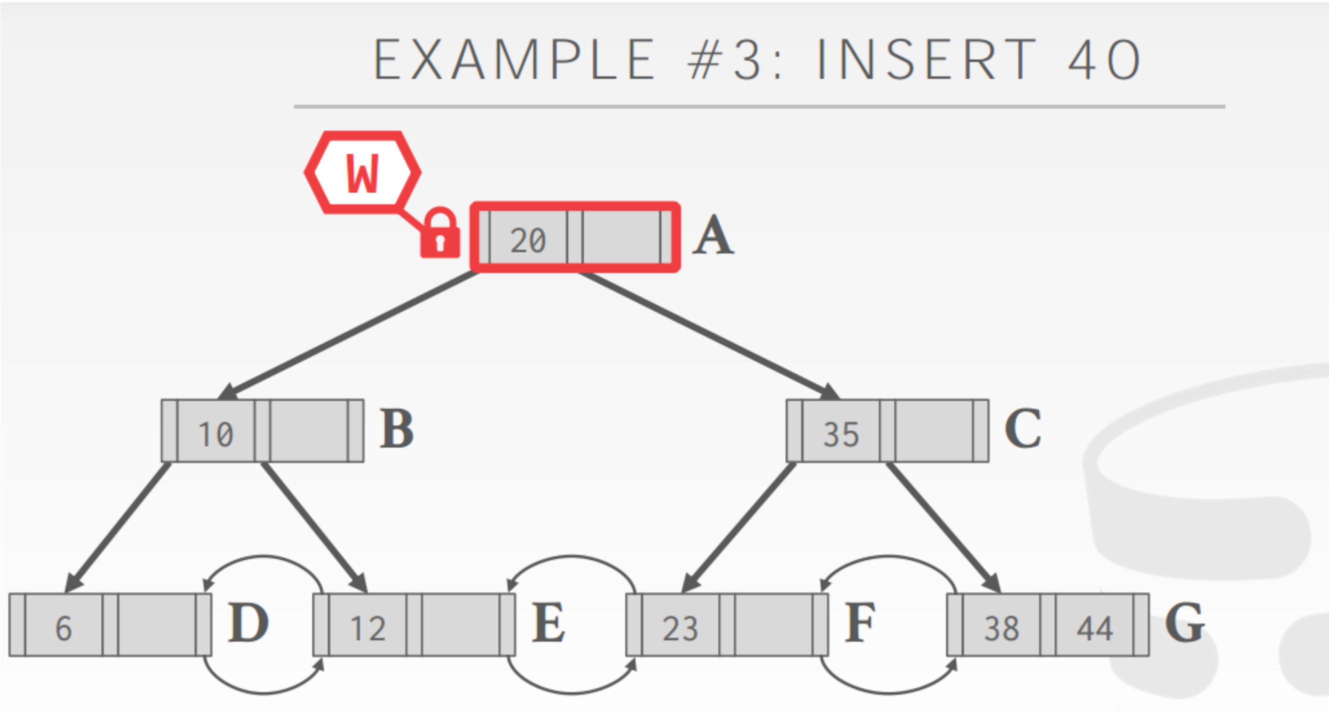

对于插入操作而言，重要的是判断C结点的子节点分裂的时候，C结点还有没有空间容纳。这里是有的，因此它是安全的，可以释放掉A的锁。

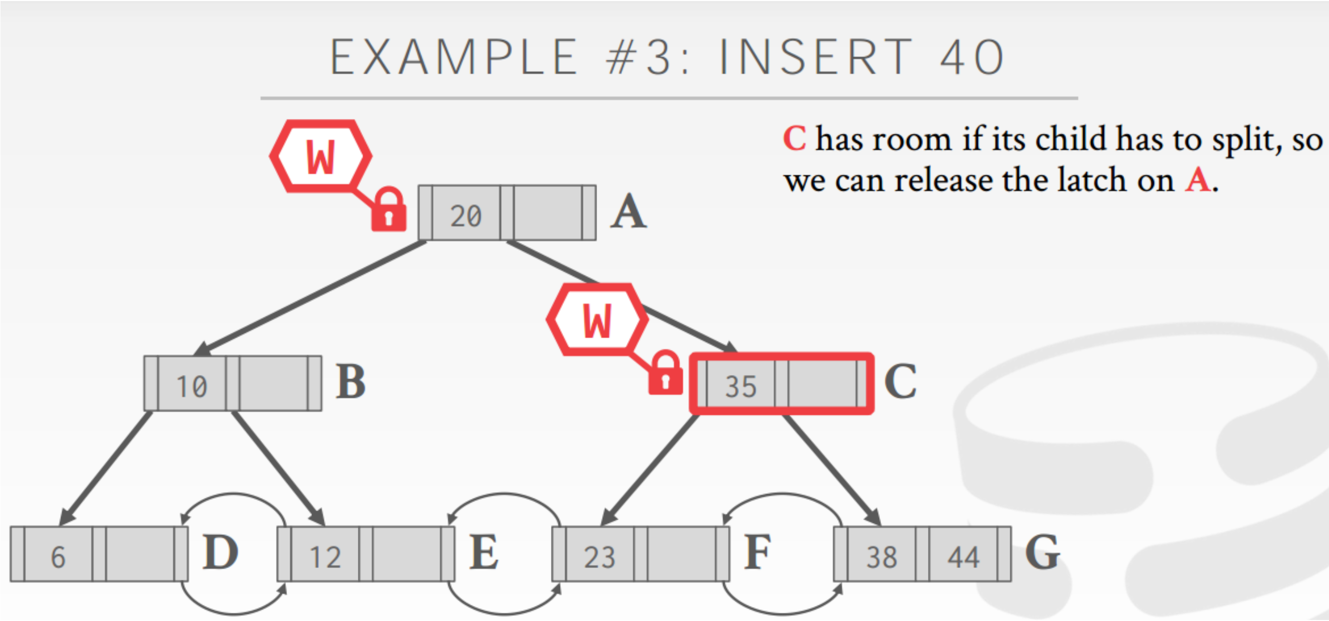

这时候插入40，G一定要split，G不安全，因此不能释放C的锁

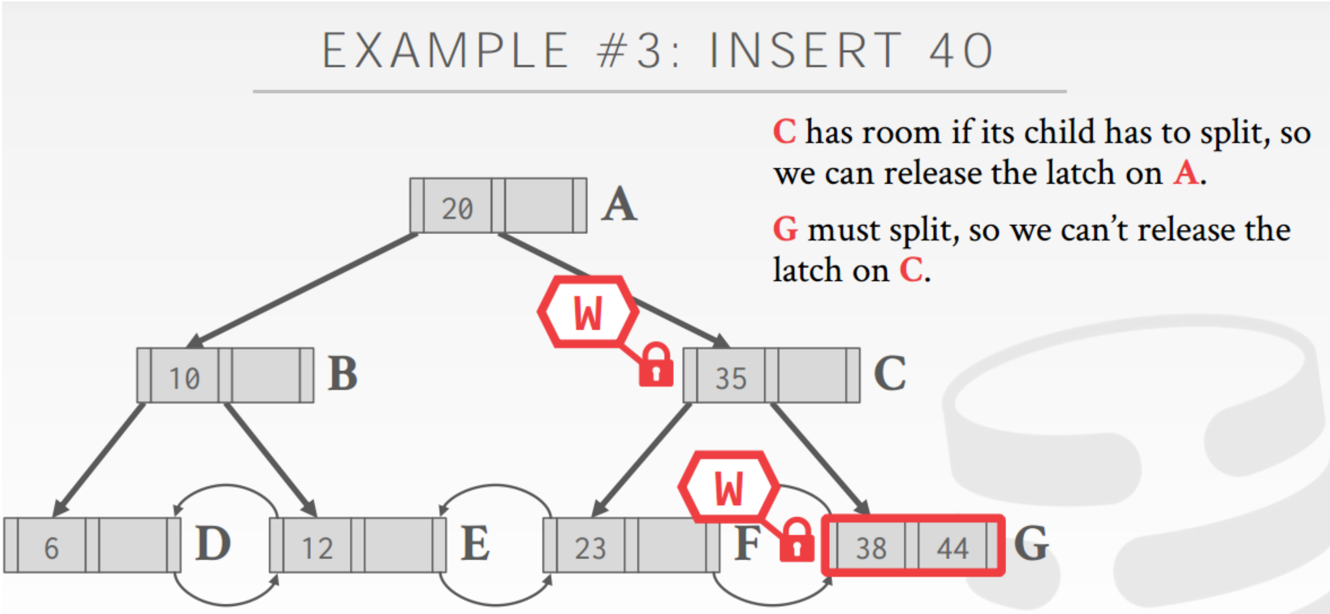

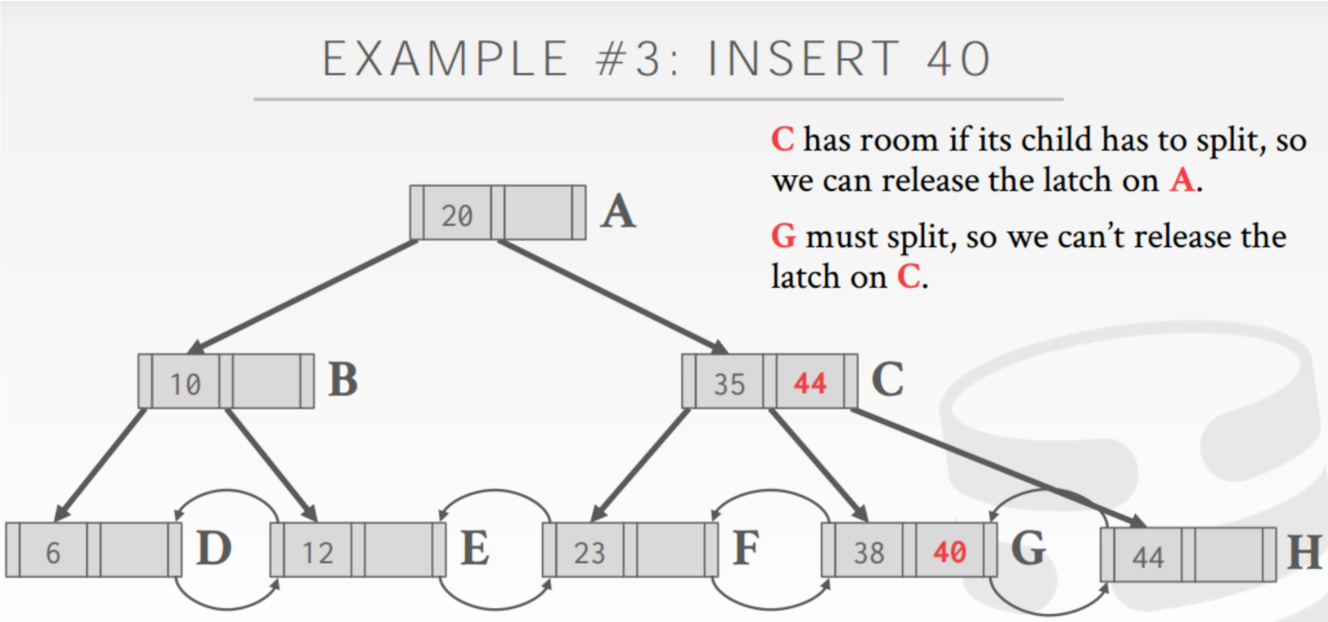

但是上面这种方法效率有点低，因为ancestor node随时要上一个Write Latch,可能会block掉其他的读请求。所以我们可以采取以下方法：

乐观认为子节点是Safe的，上的是读锁，那么一旦子节点安全就可以释放掉父节点的读锁，避免block掉其他请求。如果不安全，就只好按照上面那种思路来，上写锁了。

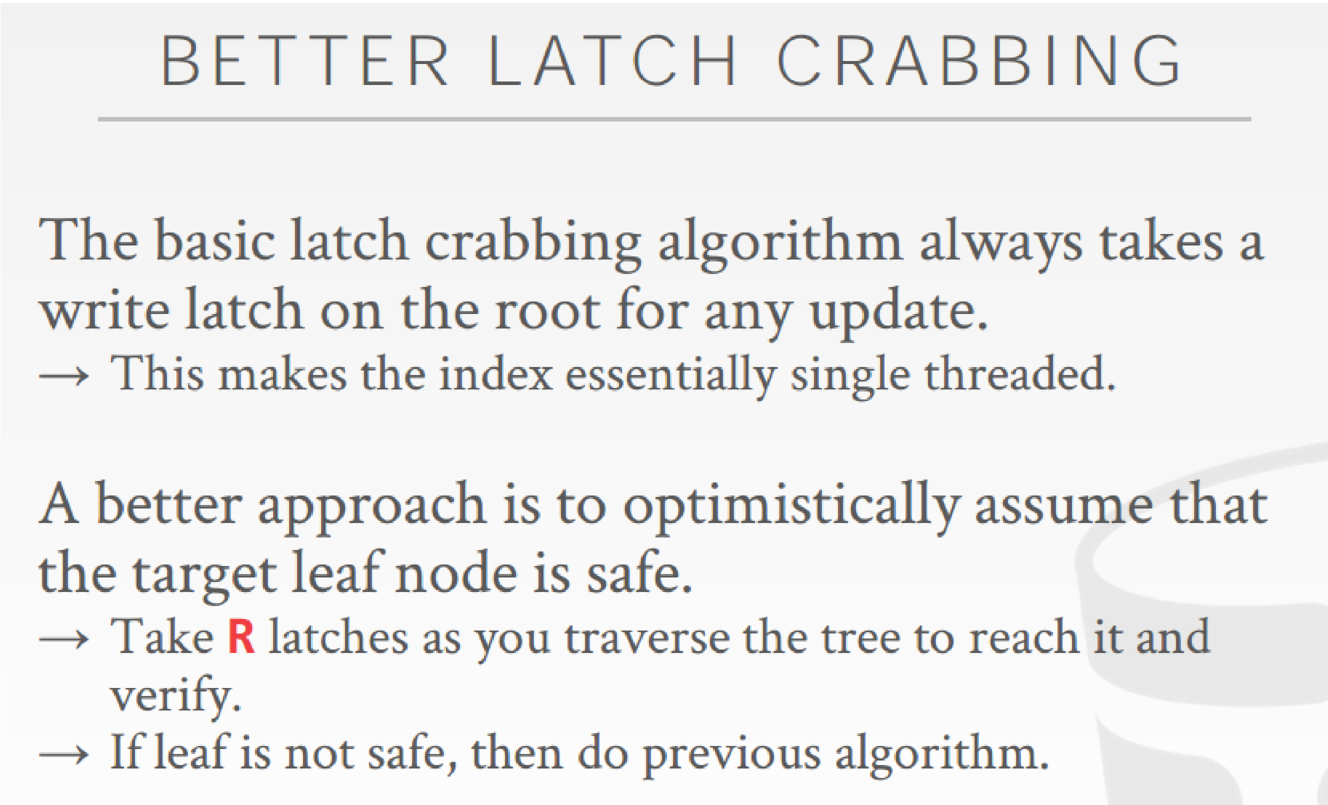

还是以delete 44为例子

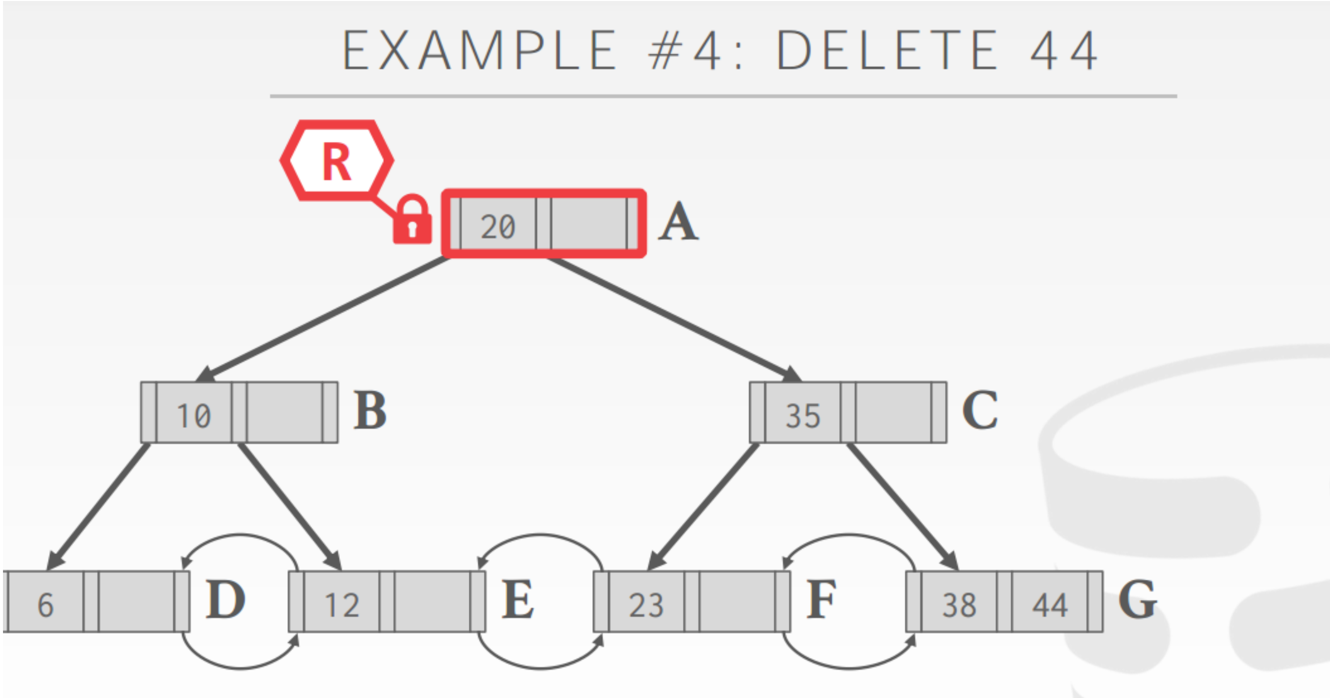

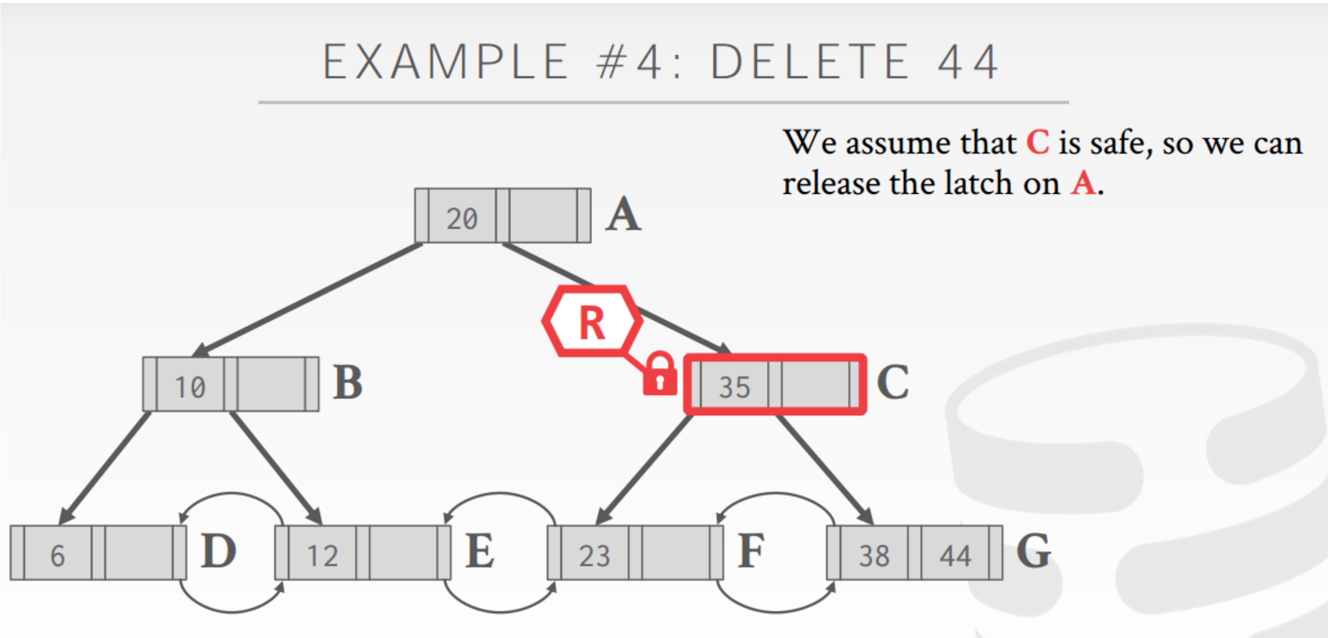

因为delete44不会merge掉G，因此可以释放掉C的latch

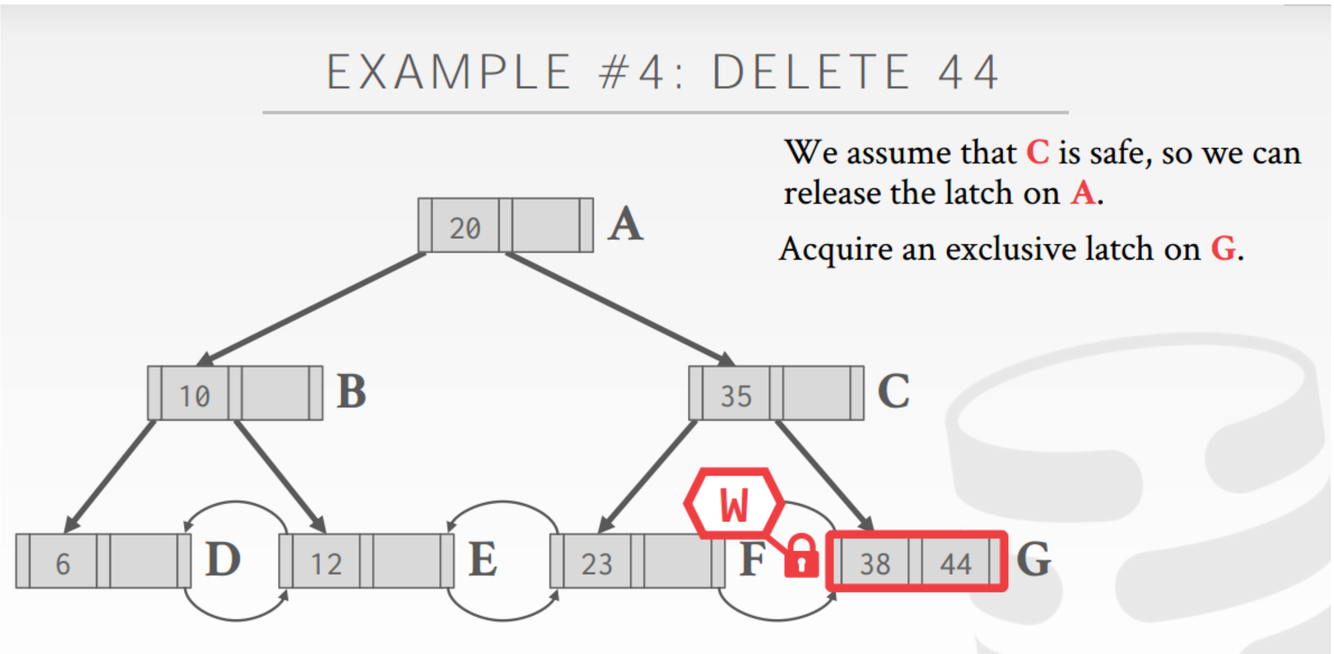

更好的方法：基于版本号机制：

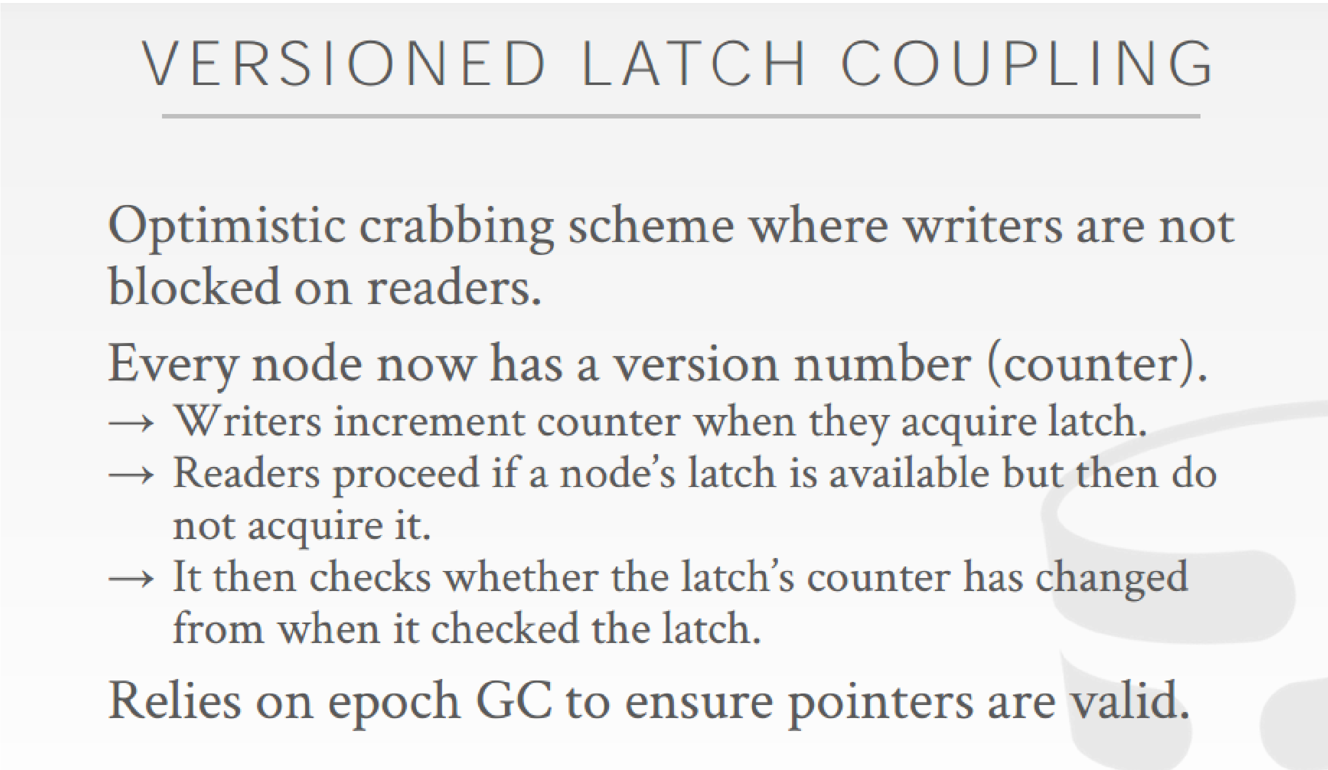

注意PPT中的@B应该是@C,@C应该是@G

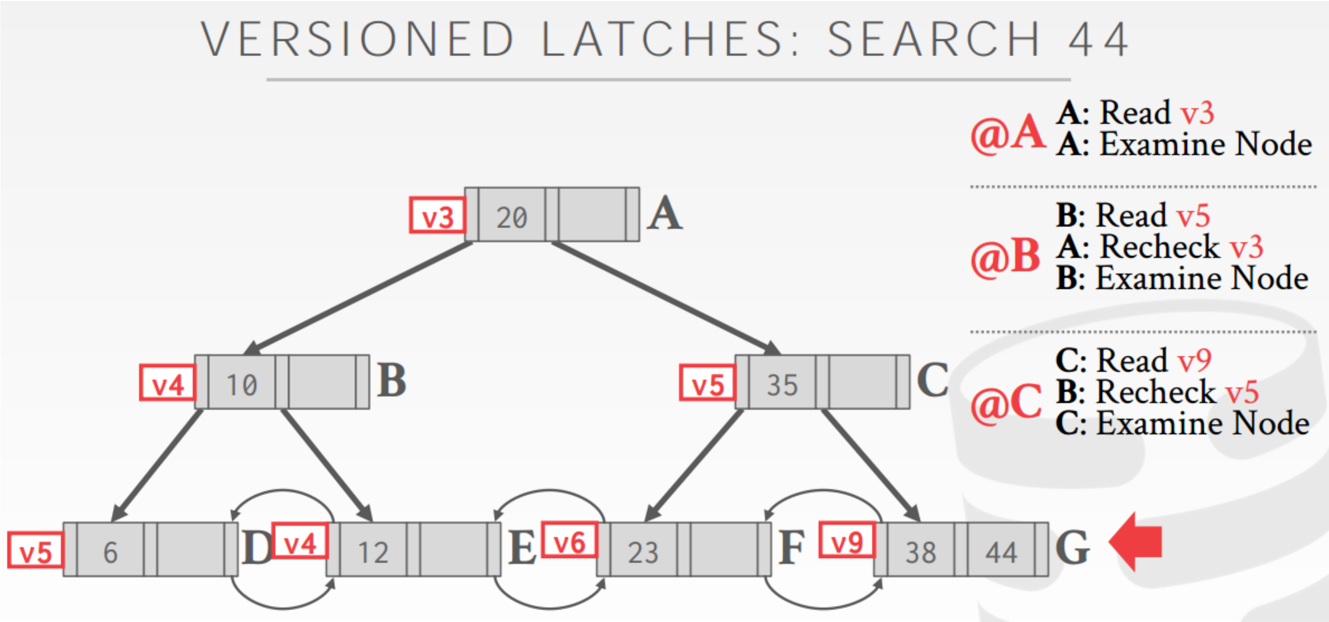

每读一个Node，都会检查其父节点的版本号是否改变。如果改变了，有可能涉及到结点的split/merge导致结点路径改变。那么走原来的老路径可能就会search不到。

如果在读G结点的时候，有线程修改了C，C的版本号·发生了改变那么G的recheck就会失败，这时候就只能从头开始来了。

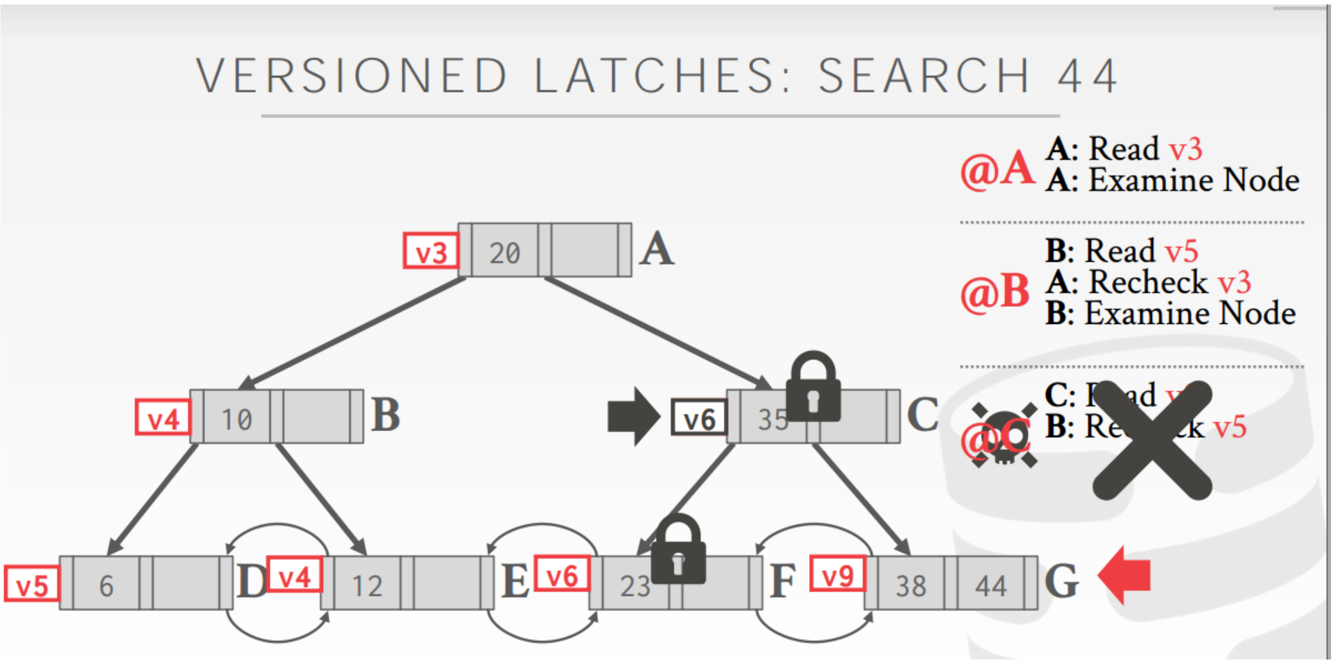

Trie

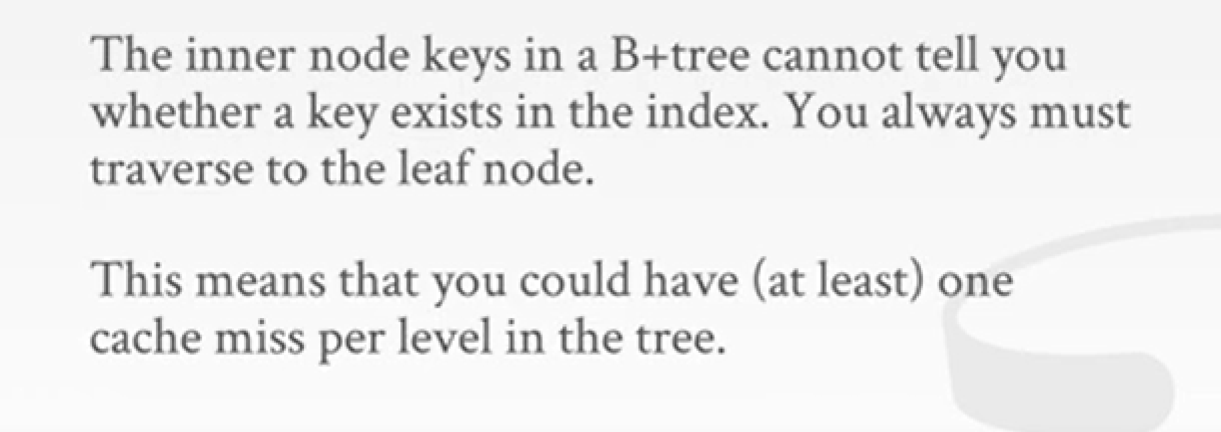

B+树的数据都是在叶子节点，内部节点不能告诉你某个key是否存在。为了寻找某个数据，你可能需要从头遍历到叶子节点。那么每一层都其实会对应一个缓存行的失效。

于是我们引入字典树，方便做前缀匹配加速查找。

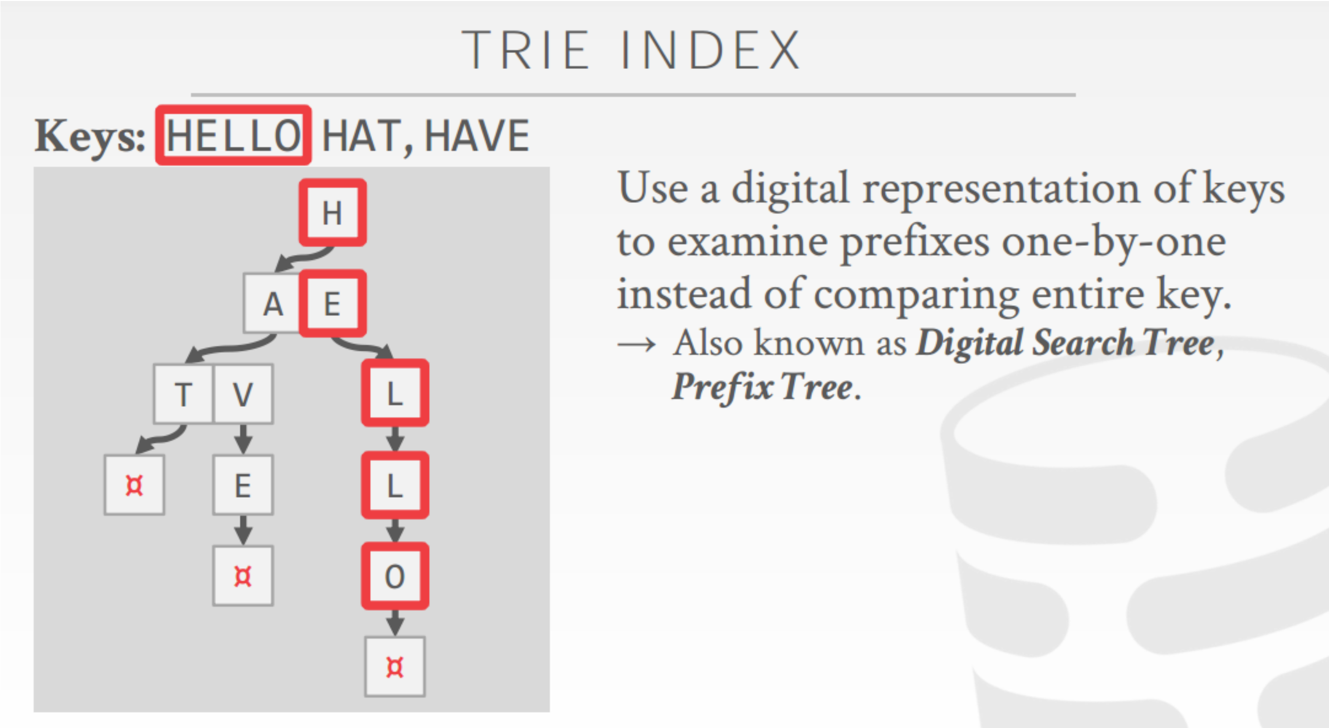

那么search操作就没有必要都遍历到叶子节点才能找到某个key是否存在，在字典树中所有操作的时间复杂度为O(length)

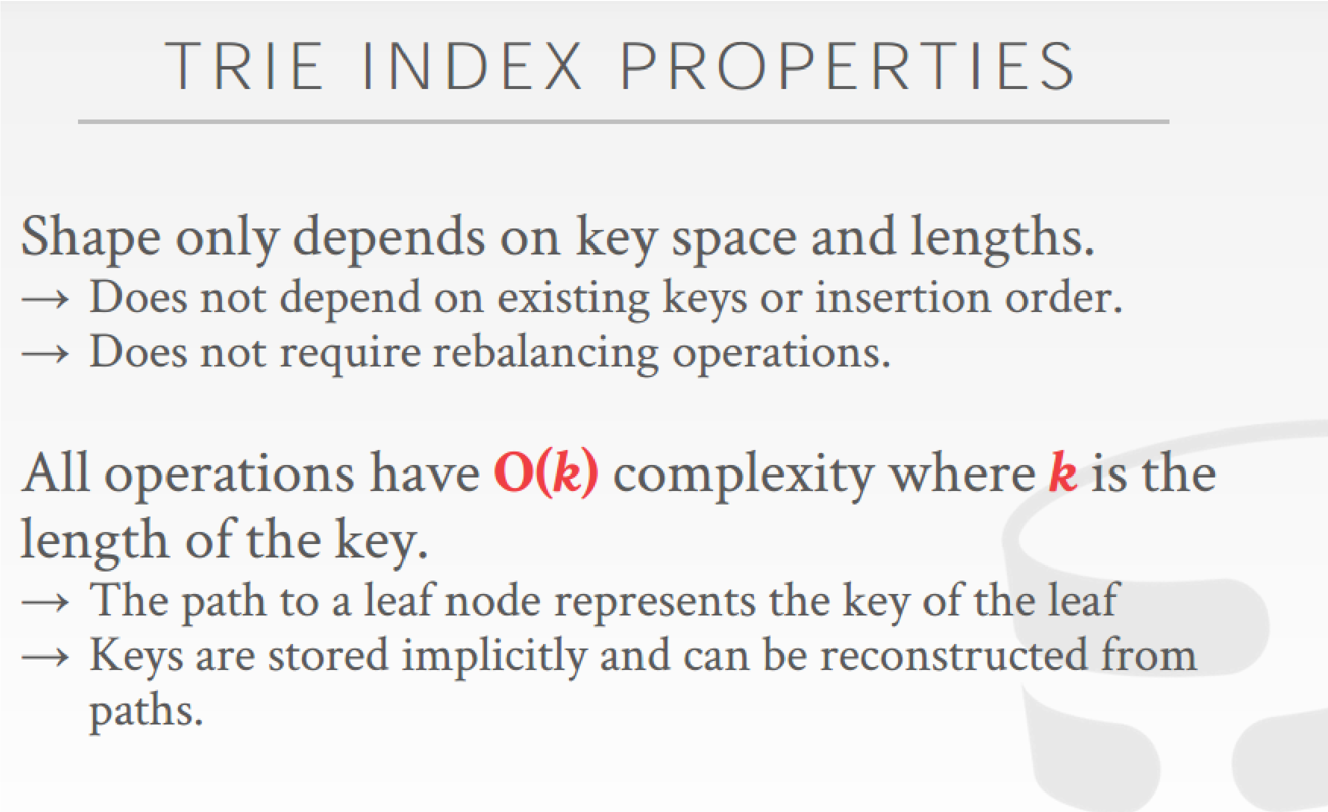

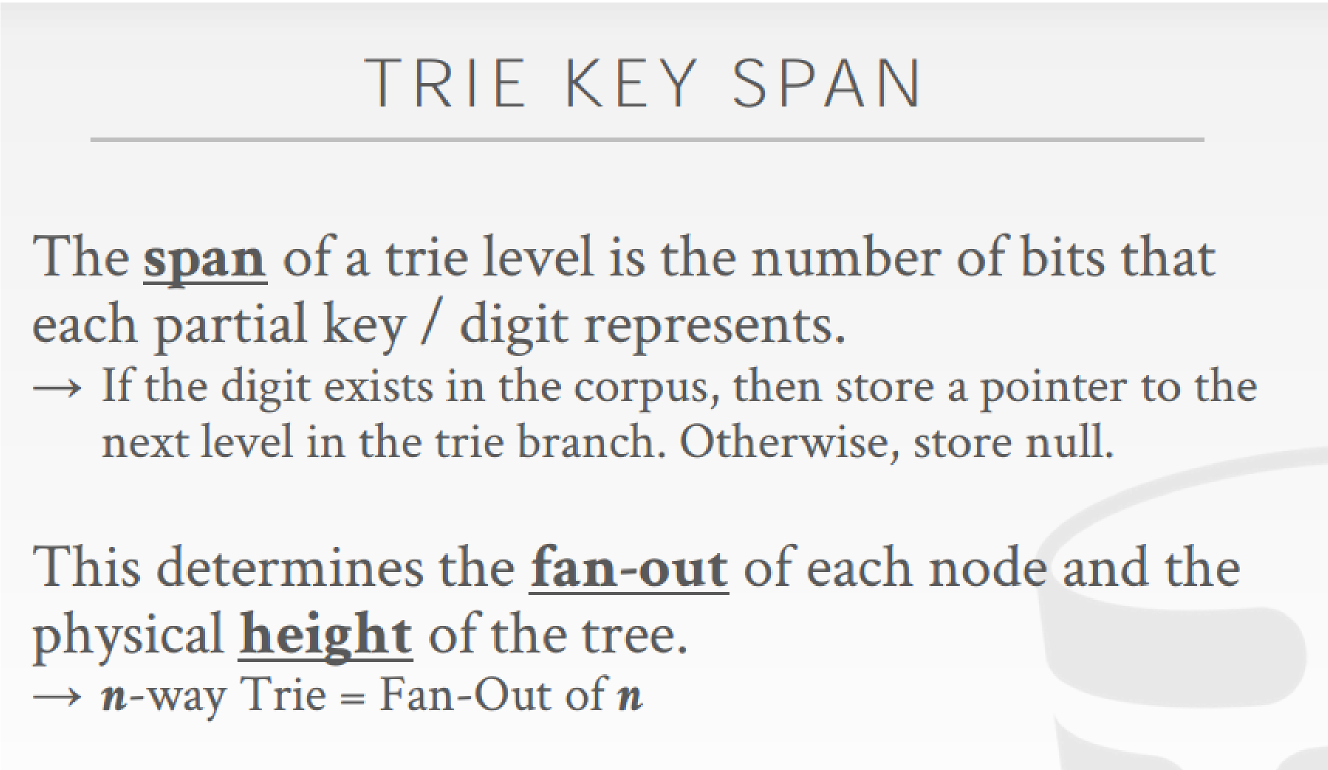

一种表示方式如下图所示:

每个结点2项,如果该位是0则第一项指向下一个结点，如果是1就第二项指向下一个结点

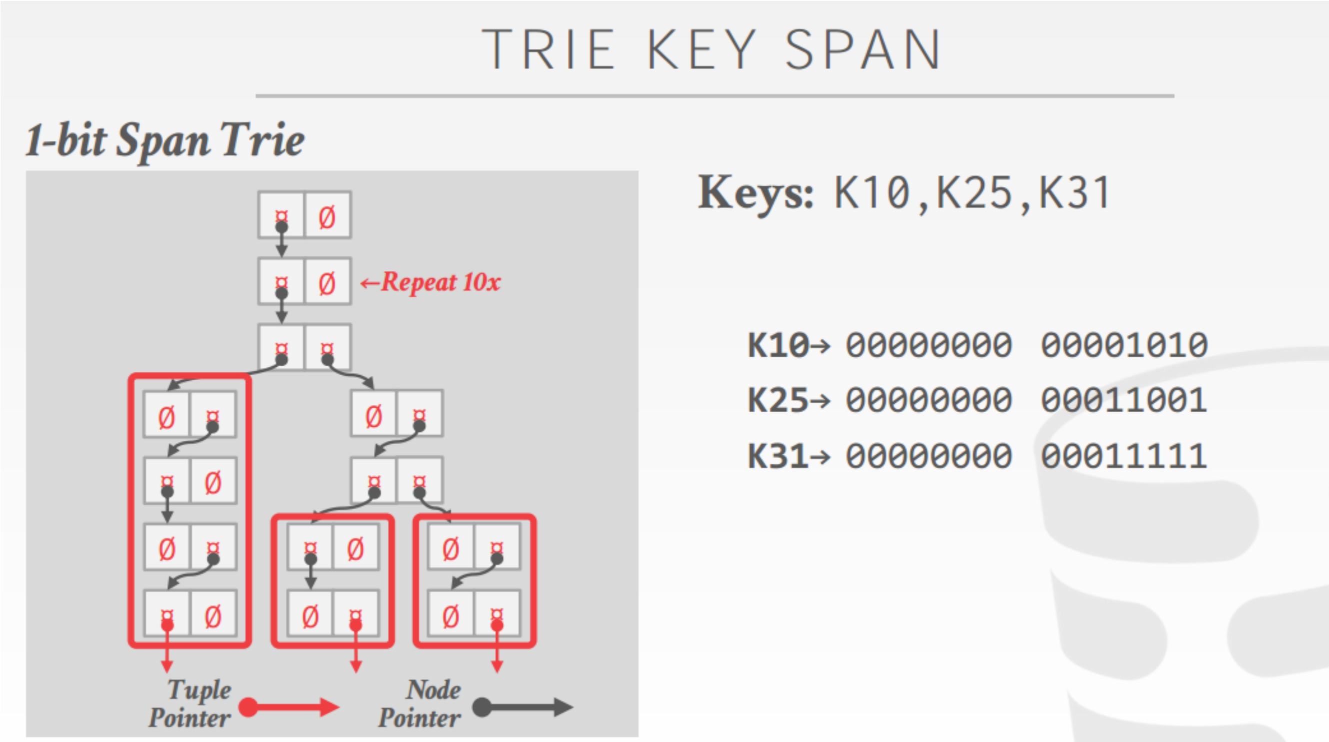

Radix Tree

压缩版本的Trie

A radix tree is a compressed version of a trie. In a trie, on each edge you write a single letter, while in a PATRICIA tree (or radix tree) you store whole words.

Now, assume you have the words `hello`, `hat` and `have`. To store them in a *trie*, it would look like:

```
    e - l - l - o
  /
h - a - t
      \
       v - e
```

And you need nine nodes. I have placed the letters in the nodes, but in fact they label the edges.

In a radix tree, you will have:

```
             *
            /
         (ello)
          /
* - h - * -(a) - * - (t) - *
                  \
                  (ve)
                    \
                     *
```

and you need only five nodes. In the picture above nodes are the asterisks.

So, overall, a radix tree takes *less memory*, but it is harder to implement. Otherwise the use case of both is pretty much the same.

ref

https://zhuanlan.zhihu.com/p/89058726